

文献综述

随着数字文档处理与自然语言处理技术的发展，基于语义理解的文档自动排版逐渐成为研究热点。本文所涉及的技术基础主要包括 DOCX 文档结构解析、XML 数据建模以及大语言模型（LLM）在文本理解与结构化中的应用。

1. DOCX 文档结构与底层表示

DOCX 文件本质上是一种基于 XML 的压缩文档格式，其内部结构由多个 XML 文件组成，用于描述文本内容、样式信息及文档布局。Bourret[3] 与 Abiteboul[4] 早期对 XML 与数据库及视图机制的研究，为结构化文档的解析与重组提供了理论基础。这些研究指出，XML 具备良好的层级结构表达能力，适合描述复杂文档对象及其语义关系。

在 DOCX 具体应用方面，Naser 等[1] 从安全分析角度研究了 DOCX 文件的内部结构，揭示了其 XML 层级中隐藏信息的可能性；Kaczyński[2] 则进一步提出利用 DOCX 进行隐写通信的方法，说明 DOCX 不仅是文档载体，同时也是一种可编码复杂信息结构的数据容器。这些研究从侧面证明了 DOCX 底层 XML 结构的灵活性与可操作性，为基于 Python（如 python-docx）进行文档结构解析与重构提供了技术依据。

2. NLP 与文本结构化研究

自然语言处理（NLP）在文本理解与信息抽取方面的研究为语义排版提供了核心支撑。Kang 等[5] 对 NLP 在管理研究中的应用进行了系统综述，指出文本分析、语义建模和信息抽取是当前主要研究方向。化柏林[8] 提出了基于 NLP 的知识抽取系统架构，为文本语义结构化提供了通用框架。

在具体应用层面，乔宝榆[7] 基于 NLP 构建辅助审稿系统，通过语义分析实现对论文结构和内容的自动评估；肖晓霞等[9] 提出了中医医案文本的快速结构化方法，利用 NLP 技术将非结构化文本转化为结构化数据；黄大吉等[10] 则将嵌入式 NLP 应用于专业术语识别，提升了特定领域文本处理的准确性。这些研究表明，NLP 技术已能够较为成熟地实现文本语义识别与结构化处理，但多数仍依赖规则或传统机器学习方法，在复杂语义理解方面存在局限。

3. 大语言模型（LLM）与语义理解

近年来，大语言模型（LLM）显著提升了自然语言理解与生成能力。Zaremba 与 Demir[6] 指出，以 ChatGPT 为代表的 LLM 在金融等领域展现出强大的语义理解与推理能力，能够处理复杂文本任务。相比传统 NLP 方法，LLM 具备更

强的上下文建模能力和跨任务泛化能力，为语义驱动文档处理提供了新的技术路径。

结合上述研究可以看出，LLM 在文本分类、结构识别及内容重组方面具有天然优势，能够弥补传统 NLP 在规则依赖和泛化能力上的不足。因此，将 LLM 引入文档排版领域，有望实现从“基于格式规则的排版”向“基于语义理解的排版”的转变。

4. 现有研究的不足与本文工作

综上所述，现有研究在以下方面仍存在不足：

- （1）DOCX 文档处理多集中于底层结构解析，缺乏与语义理解的深度结合；
- （2）传统 NLP 方法在复杂文档结构识别中依赖规则较多，灵活性不足；
- （3）LLM 虽在文本理解方面表现突出，但在文档排版领域的系统化应用仍较少。

针对上述问题，本文提出一种基于 Python 与大语言模型的语义式排版方法。该方法以 python-docx 为基础，实现 DOCX 文档结构的读取与修改；结合 XML 层级信息进行精细化控制；同时引入 LLM 对文档内容进行语义分析与结构识别，从而实现自动化、智能化的文档排版。